



Universidade de Brasília - UnB  
Faculdade UnB Gama - FGA  
Engenharia Eletrônica

# **Inteligência Artificial para Determinar a Fase de Uma Antena**

Autor: Jessica Kamily Oliveira de Sousa  
Orientador: Prof. Dr. Sébastien Rondineau

Brasília, DF  
2019





Jessica Kamily Oliveira de Sousa

# **Inteligência Artificial para Determinar a Fase de Uma Antena**

Monografia submetida ao curso de graduação em Engenharia Eletrônica da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia Eletrônica.

Universidade de Brasília - UnB

Faculdade UnB Gama - FGA

Orientador: Prof. Dr. Sébastien Rondineau

Brasília, DF

2019

---

Jessica Kamily Oliveira de Sousa

Inteligência Artificial para Determinar a Fase de Uma Antena/ Jessica Kamily  
Oliveira de Sousa. – Brasília, DF, 2019-  
57 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Sébastien Rondineau

Trabalho de Conclusão de Curso – Universidade de Brasília - UnB  
Faculdade UnB Gama - FGA , 2019.

1. Inteligência Artificial. 2. Antena. I. Prof. Dr. Sébastien Rondineau. II.  
Universidade de Brasília. III. Faculdade UnB Gama. IV. Inteligência Artificial  
para Determinar a Fase de Uma Antena

CDU 02:141:005.6

---

Jessica Kamily Oliveira de Sousa

## **Inteligência Artificial para Determinar a Fase de Uma Antena**

Monografia submetida ao curso de graduação em Engenharia Eletrônica da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia Eletrônica.

Trabalho aprovado. Brasília, DF, 01 de junho de 2013:

---

**Prof. Dr. Sébastien Rondineau**  
Orientador

---

**Titulação e Nome do Professor**  
**Convidado 01**  
Convidado 1

---

**Titulação e Nome do Professor**  
**Convidado 02**  
Convidado 2

Brasília, DF  
2019



*Dedico este trabalho a todos aqueles que através da ciência buscam mudar o mundo.*





# Agradecimentos

Agradeço todos aqueles que passaram pela minha vida contribuindo para o meu crescimento pessoal e profissional. Acreditaram no meu potencial e conseguiram ver além do que eu tinha para demonstrar.

Aos que me apoiaram e me deram suporte para que eu pudesse alcançar os objetivos traçados como meta individual, no entanto me ajudarão a colher os frutos dessa caminhada.

Aos amigos que me proporcionam momentos únicos e fazem dessa jornada uma experiência ímpar, divertida e eternizada.

Aos professores, por todo o conhecimento fornecido dentro e fora da sala. Os aprendizados, experiências e conselhos.

Aos familiares que sonharam e vivem a graduação junto comigo, mesmo que de maneira compulsória. Me ensinando o significado de resiliência na prática, todas as vezes em que pensei em desistir(não foram poucas).

A mim, por ter conseguido chegar até aqui, com tantos percalços e contratempos e ter forças para ir além.



*“(...)As coisas tangíveis  
tornam-se insensíveis  
à palma da mão.  
Mas as coisas findas,  
muito mais que lindas,  
essas ficarão.”*

*(Carlos Drummond de Andrade)*



# Resumo

A recuperação de fase é um problema antigo que surge em aplicações da teoria eletromagnética, quando a fase é aparentemente perdida ou sua medida impraticável. A matemática do problema fornece uma ideia da natureza dos campos eletromagnéticos em estudo, no entanto a ausência da informação da fase, pode apresentar ambiguidades na análise dos resultados. O processamento adicional do objeto de estudo passa a ser necessário para obter a fase. A aplicação de métodos numéricos e o uso de procedimentos computacionais temáticos se torna indispensável para esse tipo de problema. Por ventura, os sistemas computacionais encontram-se cada vez mais potentes e com alta capacidade de processamento, sendo impulsionados por algoritmos e programas desenvolvidos para tratar grande quantidade de dados. A necessidade de aumentar a autonomia das máquinas e obter análises cada vez mais precisas e rápidas, é de extrema importância para estudos científicos e evolução tecnológica, estimulando o desenvolvimento de metodologias como por exemplo o *machine learning*, tornando possível que a máquina processe um grande número de informação e forneça um resultado a partir do que lhe for solicitado. O referencial teórico é fundamental para que possa se fazer o levantamento dos estudos realizados e como está sendo feita a empregabilidade dos adventos computacionais para solução de problemas, antes considerados irresolúveis. O estudo bibliográfico foi dividido entre a contextualização referente a inteligência artificial, os métodos nela contidos, os algoritmos mais utilizados e suas aplicações, por outro lado o levantamento teórico dos requisitos de categorização paramétrica das antenas e seu formalismo teórico, por fim os métodos adotados para o contorno do problema de fase e soluções adotadas em áreas correlatadas das engenharias. Com isso, foi possível constatar uma significativa evolução no desenvolvimento de algoritmos utilizados para reconstrução de informação a partir de dados existentes. Todo o estudo e formalismo aqui levantados servirão de apoio para o desenvolvimento de uma inteligência artificial capaz de extrair as informações de fase, com o intuito de definir o comportamento de campo distante de antenas que operem em diferentes bandas e frequências.

**Palavras-chaves:** Inteligência Artificial, Aprendizado de Máquina, Eletromagnetismo Avançado, Antenas, Medições de Antena, Recuperação de Fase, Problema de Fase.



# Abstract

Phase retrieval is an old problem that arises in applications of electromagnetic theory when the phase is apparently lost or its measurement impractical. The mathematics of the problem provides an idea of the nature of the electromagnetic fields under study, however the absence of phase information may present ambiguities in the analysis of the results. Further processing of the study object becomes necessary to obtain the phase. The application of numerical methods and the use of computational procedures becomes indispensable for this type of problem. Perhaps, computer systems are increasingly powerful and with high processing capacity, being driven by algorithms and programs designed to handle large amounts of data. The need to increase machine autonomy and obtain ever more accurate and rapid analysis is of utmost importance for scientific studies and technological evolution, stimulating the development of methodologies such as Machine Learning, making it possible for the machine to process large numbers of information and provide a result from what you asked to do. The theoretical framework is fundamental for the survey of the studies and how the employability of computational advent for problem solving, previously considered unresolvable, is being done. The bibliographic study was divided between the contextualization referring to artificial intelligence, the methods contained in it, the most used algorithms and their applications, on the other hand the theoretical survey of the parametric categorization requirements of the antennas and their theoretical formalism, finally the methods adopted for the phase problem contour and solutions adopted in related areas of engineering. Thus, it was possible to verify a significant evolution in the development of algorithms used to reconstruct information from existing data. All of the study and formalism raised here will support the development of artificial intelligence capable of extracting phase information to define the far-field behavior of antennas operating in different bands and frequencies.

**Key-words:** Artificial Intelligence, Machine Learning, Advanced Electromagnetism, Antennan, Antenna measurements, Phase Retrieval, Phase Problem.





# Lista de ilustrações

Figura 1 – Representação de uma árvore de decisão simplificada . . . . .	32
Figura 2 – Ilustração de classificação de um elemento (círculo) em relação aos vizinhos (triângulos e quadrados) . . . . .	32
Figura 3 – Representação de hiperplanos gerados entre os vetores, comparados ao processo pós-aprendizado com o hiperplano otimizado . . . . .	33
Figura 4 – Esquemático de uma rede neural . . . . .	34
Figura 5 – Regiões de campo . . . . .	39
Figura 6 – Esquemático do algoritmo para determinar fase. Fonte: (GERCHBERG; SAXTON, 1972) . . . . .	44
Figura 7 – Relação entre fluxo de corrente, campo e potencial . . . . .	48
Figura 8 – Antena do tipo Corneta Piramidal . . . . .	49



# Lista de tabelas

Tabela 1 – Propriedades obtidas após processamento . . . . .	52
--	----



# Lista de abreviaturas e siglas

Fig.            Area of the  $i^{th}$  component

456            Isto é um número

123            Isto é outro número

lauro cesar    este é o meu nome



# Lista de símbolos

$\nabla$	Operador gradiente
$\nabla \cdot$	Operador divergente
$\nabla \times$	Operador rotacional
$\nabla^2$	Operador Laplaciano
$\mathcal{E}$	Intensidade de Campo Elétrico (V/m)
$\mathcal{M}$	Densidade de Corrente Magnética (V/m <sup>2</sup> )
$\mathcal{B}$	Densidade de Fluxo Magnético (Wb/m <sup>2</sup> )
$\mathcal{H}$	Intensidade de Campo Magnético (A/m)
$\mathcal{J}$	Densidade de Corrente Elétrica (A/m <sup>2</sup> )
$\mathcal{D}$	Densidade de Fluxo Elétrico (C/m <sup>2</sup> )
$\rho$	Densidade de carga elétrica (C/m <sup>3</sup> )
$\Psi$	Função de onda escalar
$j$	Unidade imaginária ( $j^2 = -1$ )





# Sumário

	<b>Introdução</b>	<b>25</b>
<b>I</b>	<b>REFERENCIAL TEÓRICO</b>	<b>27</b>
<b>1</b>	<b>INTELIGÊNCIA ARTIFICIAL</b>	<b>29</b>
<b>1.1</b>	<b>Aprendizado de Máquina</b>	<b>29</b>
1.1.1	Aprendizado Supervisionado	30
1.1.1.1	Regressão	30
1.1.1.2	Classificação	32
1.1.2	Aprendizado Não-supervisionado	33
1.1.3	Aprendizado por reforço	34
<b>1.2</b>	<b>Deep Learning</b>	<b>34</b>
<b>2</b>	<b>ANTENAS</b>	<b>35</b>
<b>2.1</b>	<b>EQUAÇÕES DE MAXWELL</b>	<b>35</b>
<b>2.2</b>	<b>EQUAÇÃO DE ONDA</b>	<b>36</b>
2.2.1	Equação de Onda de Helmholtz	36
2.2.2	Solução para a Equação de Onda	37
2.2.3	Solução para Equação de Onda Vetorial	38
2.2.4	Solução para Equação de Onda do Campo Eletromagnético	38
<b>2.3</b>	<b>PARÂMETROS FUNDAMENTAIS</b>	<b>39</b>
2.3.1	Região de Campo	39
2.3.2	Diagrama de radiação	40
2.3.3	Vetor de Poynting	40
2.3.4	Diretividade	40
2.3.5	Métodos Numéricos	41
<b>3</b>	<b>PROBLEMA DE FASE</b>	<b>43</b>
<b>3.1</b>	<b>TRANSFORMADA DE FOURIER</b>	<b>43</b>
<b>3.2</b>	<b>RECUPERAÇÃO DE FASE</b>	<b>43</b>
<b>3.3</b>	<b>ALGORITMOS PARA RECUPERAÇÃO DE FASE</b>	<b>44</b>
<b>II</b>	<b>PROPOSTA</b>	<b>45</b>
<b>4</b>	<b>METODOLOGIA</b>	<b>47</b>

4.1	JUSTIFICATIVA . . . . .	47
4.2	OBJETIVOS . . . . .	47
4.2.1	Objetivo específico . . . . .	47
4.3	Procedimento . . . . .	48
4.4	Métodos de Análise . . . . .	49
4.5	Simulação . . . . .	49
5	ELEMENTOS DO TEXTO . . . . .	51
5.1	CONCLUSÃO PARCIAL . . . . .	51
5.2	CRONOGRAMA . . . . .	51
5.3	Tabela . . . . .	51
	REFERÊNCIAS . . . . .	53
	ANEXOS . . . . .	55
	ANEXO A – VETORES DA EQUAÇÃO DE ONDA DO CAMPO ELETROMAGNÉTICO . . . . .	57

# Introdução

Este documento apresenta considerações gerais e preliminares relacionadas à redação de relatórios de Projeto de Graduação da Faculdade UnB Gama (FGA). São abordados os diferentes aspectos sobre a estrutura do trabalho, uso de programas de auxílio a edição, tiragem de cópias, encadernação, etc.



Parte I

## REFERENCIAL TEÓRICO



# 1 Inteligência Artificial

O termo “Inteligência Artificial” foi citado pela primeira vez em 1956 por John McCarthy, na conferência de Dartmouth, no qual se referia à capacidade de uma máquina de realizar determinada função que pudesse ser classificada como inteligente, se um homem fosse capaz de comportar-se de tal maneira(MCCARTHY et al., 2006)

Tendo como um dos cientistas visionários mais importante, Alan Turing (1912-1952) idealizou a Máquina de Turing, um dispositivo teórico precursor dos computadores atuais, sendo a junção de elementos matemáticos, algoritmos e lógica com a finalidade de solucionar problemas complexos.

Sua contribuição corresponde ao período da Segunda Guerra Mundial, onde pode construir o aparato físico seguindo os princípios da Máquina de Turing. E em paralelo estudando a possibilidade de máquinas apresentarem comportamento inteligente. Turing então propôs o que viria a ser conhecido por “Teste de Turing”, uma metodologia baseada em testar um sistema capaz de exibir comportamento equivalente ao do ser humano, se o sistema for indistinguível, então ele passa no teste(MIJWEL, 2015).

Desde de 1956, quando o termo "Inteligência Artificial" nascia, até os dias de hoje, muito se há mudado, no que compete à forma como os algoritmos são desenvolvidos, contextos e aplicabilidade. Isso se deve ao desenvolvimento tecnológico associado, com máquinas com alta capacidade de processamento, linguagens de desenvolvimento e maneiras na forma de geração e tratamento de dados.

Considerada um ramo da Ciência da Computação, que se ocupa com a teoria e o desenvolvimento de sistemas computacionais capazes de executar tarefas que normalmente requerem inteligência humana, como percepção, reconhecimento, análise, aprendizado, planejamento, tomadas de decisão, entre outros(SHABBIR; ANWER, 2018).

Para que uma máquina se torne inteligente ela precisa ser ensinada, tal qual uma criança que busca aprender, se adaptar e desempenhar tarefas. Composta por códigos de programação e funções matemáticas, o aprendizado é feito a partir da inserção de dados e análises. O algoritmo então é processado e os dados serão interpretados, retornando uma saída, podendo ser ela definida, conhecida ou inesperada.

## 1.1 Aprendizado de Máquina

Sendo um ramo dentro da IA, baseando-se no contexto de que um sistema pode aprender a partir da análise de dados. O Aprendizado de Máquina (do inglês *Machine Learning* - ML) é um método que automatiza a construção de modelos analíticos a partir

do treinamento da máquina(SIMEONE, 2018). O método é construído baseado no processo definido seguindo as etapas fundamentais, onde começa pela aquisição dos dados, seguido pelo preparo dos dados, desenvolvimento do modelo, previsão do resultado, inserção de dados de teste e por fim a avaliação(TAULLI, 2019; DHUMALE; THOMBARE; BANGARE, 2019).

Existem três classes principais de técnicas de aprendizado de máquina, com elas é definido como se dará o tratamento dos dados de entrada e sua relação com as saídas(SIMEONE, 2018).

### 1.1.1 Aprendizado Supervisionado

O Aprendizado Supervisionado, como o próprio nome sugere, é feito com a presença de um supervisor que será o professor para a máquina. Nesse método, um banco de dados com entradas bem definidas é fornecido, após ser treinada, a máquina fornecerá uma saída conhecida(DHUMALE; THOMBARE; BANGARE, 2019).

No processo de treinamento, são fornecidos  $N$  pares de entradas e saídas,

$$(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N), \quad (1.1)$$

onde para cada  $y$  é gerado uma função desconhecida  $y = f(x)$ , o aprendizado ocorre ao se definir uma função  $h$  que se aproxima da função verdadeira  $f$ .

É sabido que os dados de entrada  $x_i$  podem ser valores ou classes. No que compete às saídas  $y_i$  podem ser definidas como valores finitos ou classificadas de maneira binária, para o primeiro caso, o problema de aprendizado é conhecido como de regressão e o segundo como classificação(RUSSELL; NORVIG, 2010).

#### 1.1.1.1 Regressão

A regressão consiste numa técnica estatística de um modelo preditivo, permitindo ao usuário resumir e aprender a relação entre duas variáveis contínuas, estimando um valor real aproximado de saída. Quando se trata de saídas em classes discretizadas, a regressão no caso é conhecida por um problema de classificação, onde as saídas assumirão classes conhecidas, como é o caso da regressão logística (DHUMALE; THOMBARE; BANGARE, 2019).

- Regressão Linear

Se trata de um modelo linear estatístico, que assume uma relação linear entre as variáveis de entrada ( $x$ ) e uma única variável de saída ( $y$ ).



$$y = \beta_0 + \beta_1 x + \epsilon \quad (1.2)$$

A equação 1.2 combina um conjunto específico de valores de entrada e a solução é a saída prevista ( $y$ ), no qual ambos são valores numéricos.

A Regressão Linear é classificada adicionalmente em Regressão Linear Simples (SLR) e Regressão Multi-Linear (MLR). A SLR usa uma única variável independente para prever uma variável dependente ajustando um melhor relacionamento linear. Nos modelos MLR, uma variável de resposta única  $y$  depende linearmente de mais número de variáveis preditoras (DHUMALE; THOMBARE; BANGARE, 2019).

- Regressão Logística

Um algoritmo de classificação usado para atribuir observações a um conjunto discreto de classes. A regressão logística transforma a saída usando a função sigmóide logística para retornar um valor de probabilidade.

$$y = \frac{1}{1 + e^{-x}} \quad (1.3)$$

A função logística pode ser aplicada em diversas áreas, desde que a análise seja baseada em classificação binária.

- Regressão Não-Linear

Um método estatístico que ilustra a relação não-linear nos dados. Os conjuntos de dados geralmente são categorizados assim, quando suas variáveis não podem ser relacionadas por aproximação de uma linha reta.

Os modelos NLR são comumente assumidos como paramétricos e o modelo é ilustrado como uma equação não linear.

$$y = f(x, \beta) + \epsilon \quad (1.4)$$

Onde  $x$  é um vetor preditor,  $\beta$  representa a estimativa não-linear de parâmetros a serem calculadas seja na forma exponencial, de potência, trigonométrica ou quaisquer outras funções não-lineares.

Como exemplo de algoritmos de regressão não-linear, pode ser citado o algoritmo Gauss-Newton, Gradiente descendente e Levenberg-Marquardt (DHUMALE; THOMBARE; BANGARE, 2019)

### 1.1.1.2 Classificação

Os algoritmos de classificação são utilizados quando as variáveis de saídas podem ser agrupadas. No método classificatório, o algoritmo ilustra uma conclusão a partir de valores experimentais de entrada (DHUMALE; THOMBARE; BANGARE, 2019). Os algoritmos mais conhecidos são:

- Árvores de Decisão

O modelo de árvore de decisão é baseado em regras, representadas por meio de um mapa de possíveis resultados ou desenhada como fluxograma. O algoritmo da árvore de decisão começa com os dados iniciais (R), passando pelos nós de decisão (A), em seguida nós de probabilidade e por fim o nó de desfecho (B), deferenciados por classes (RUSSELL; NORVIG, 2010; TAULLI, 2019).




Figura 1 – Representação de uma árvore de decisão simplificada

O processo de construção da árvore de decisão pode exigir alto poder computacional, dado ao alto nível de pureza dos subconjuntos criados a partir dos dados. Se trata de definir as regras de modo a obter o maior ganho de informação possível, com menor entropia (RUSSELL; NORVIG, 2010).

- K-Vizinhos Mais Próximos

O K-vizinhos mais próximos (do inglês *K-Nearest Neighbor* - KNN) é uma técnica implementada para buscar e classificar um elemento de acordo com seus vizinhos. Tal método não requer processamento na fase de treinamento, entretanto requer um grande número de padrões de treinamento, cuja classe é inicialmente conhecida (TAULLI, 2019).




Figura 2 – Ilustração de classificação de um elemento (círculo) em relação aos vizinhos (triângulos e quadrados)

A ideia principal do KNN é determinar o rótulo de classificação de uma amostra baseado nas amostras vizinhas advindas de um conjunto de treinamento, conforme observado no exemplo da Fig.1.1.1.2(KELLER; GRAY; GIVENS, 1985).

- Máquina de Vetores de Suporte Nesse algoritmo, a classificação é dada a partir de hiperplanos em espaços N-dimensionais. Por exemplo, para separar duas classes de dados, há inúmeras possibilidades de se definir esses hiperplanos. O objetivo então é encontrar um plano, no qual consiste na máxima distância entre os dados das classes existentes(LORENA; CARVALHO, 2007).




Figura 3 – Representação de hiperplanos gerados entre os vetores, comparados ao processo pós-aprendizado com o hiperplano otimizado

### 1.1.2 Aprendizado Não-supervisionado

O treinamento da máquina a partir do aprendizado não-supervisionado se dá através de entradas conhecidas e saídas desconhecidas formadas por similaridade. O mecanismo de treinamento ocorre sem a supervisão, uma vez que somente os dados de entrada são fornecidos. O objetivo é buscar a representação dos dados que preserve o máximo possível de informações sobre a entrada, enquanto mantém-se a representação o mais simples e acessível(GOODFELLOW; BENGIO; COURVILLE, 2016).

Nesse processo, o aprendizado pode ser dar a partir do método de agrupamento (*clustering*) ou associação. O primeiro é usado para determinar as classes inerentes aos dados, enquanto o segundo é usado para aprender onde determinar regras que expressam grandes porções de dados de entrada(DHUMALE; THOMBARE; BANGARE, 2019).

- *K-Means Clustering*

O algoritmo mais utilizado no método de aprendizado não-supervisionado, onde trabalha iterativamente para atribuir cada ponto de dados a um dos grupos  $K$  com base nos recursos fornecidos. O processo para agrupamento de dados se baseia no conceito de similaridade, ou seja, a ideia principal é encontrar itens semelhantes de acordo com seus atributos(TAULLI, 2019).

Geralmente aplicados a dados que possuem quantidades limitadas de dimensões, onde se tem uma quantidade dados similares dentro de uma coleção distribuída aleatoriamente. Tendo origem e ainda sendo comumente aplicado em análise e processamento de sinais(MAJHI; S.SABYASACHI; MISHRA, 2014).

### 1.1.3 Aprendizado por reforço

O aprendizado por reforço (RF) é uma parte da ML relacionada à maneira como os agentes de software precisam agir em uma situação para maximizar vários conceitos de recompensa cumulativa. O modelo é treinado com a própria resposta enquanto está em RL, no entanto o agente toma decisões para que o mecanismo possa executar a tarefa especificada. Na falta de conjunto de dados de treinamento, ele é obrigado a aprender por experiência. Esse tipo de o aprendizado é usado na teoria dos jogos, teoria de controle, pesquisa operacional etc(DHUMALE; THOMBARE; BANGARE, 2019).

## 1.2 Deep Learning

*Deep Learning* (DL) é um subconjunto do Aprendizado de Máquina composta por algoritmos que permitem que o software se treine para realizar tarefas. Esse tipo de sistema permite processar grandes quantidades de dados para encontrar relacionamentos e padrões que os humanos geralmente não conseguem detectar. A palavra “*deep*” refere-se ao número de camadas ocultas na rede neural, que fornecem grande parte do poder de aprender(DHUMALE; THOMBARE; BANGARE, 2019; TAULLI, 2019).




Figura 4 – Esquemático de uma rede neural

As redes neurais artificiais profundas são formadas a partir do *deep learning*, sendo um conjunto de algoritmos que estabelecem novos registros com precisão para muitos problemas importantes, como reconhecimento de imagem, reconhecimento de som, sistemas de recomendação, processamento de linguagem natural etc(TAULLI, 2019).

## 2 ANTENAS

Uma antena é definida como um dispositivo linear passivo recíproco, isso implica que sua utilização pode ser feita para transmissão e recepção de ondas de rádio ([IEEE. . . , 1973](#)). Em outras palavras, é o dispositivo intermédio entre espaço-livre e as linhas de transmissão, podendo estas serem cabos coaxiais ou guia de ondas. O dispositivo guia é utilizado no transporte de energia eletromagnética da fonte transmissora para a antena, ou da antena para a fonte receptora([BALANIS, 2016](#)).

A primeira antena desenvolvida, surgiu no século XIX, quando Heinrich Hertz se encubiu de comprovar experimentalmente as ondas eletromagnéticas, formuladas teoricamente por Maxwell([KRAUS, 1988](#)). O aparato desenvolvido por Hertz consistia na combinação de um dipolo (oscilador excitado por faísca) e um aro condutor com uma lacuna como antena receptora([DELLINGER, 1919](#)). No entanto, o dispositivo criado por Hertz só foi capaz de transmitir e receber ondas por uma curta distância.

Foi em 1901, que ocorreu a primeira transmissão transatlântica, com a antena criada por Guglielmo Marconi, ao aperfeiçoar a técnica já desenvolvida por Hertz, tendo a primeira aplicação para a comunicação([BELROSE, 1995](#)).

Ao longo dos anos, o modelo de Marconi foi aprimorado, para que se pudesse ter equipamentos capazes de operar em diferentes frequências. Mas só durante a Segunda Guerra Mundial que novos dispositivos foram desenvolvidos, dotados de geometrias inovadoras (aos modelos já existentes), para que se tivesse uma melhor acuracia nos sistemas de transmissão e recepção([BALANIS, 2016](#)).

Os avanços tecnológicos relacionados à computação, foram fundamentais para o desenvolvimento de antenas modernas. Dando início a uma nova era, com a introdução de modelos numéricos para tratar problemas complexos intratáveis, possibilitando assim o desenvolvimento de antenas com maior precisão.

Por ser um aparato fundamental nas comunicações, o projeto de antenas torna-se cada vez mais robusto e complexo, dada a grande possibilidade de uso e aplicações, além das suas geometrias e proporções. Todavia, ainda há muito o que ser desenvolvido e melhorado para se obter cada vez mais modelos precisos e otimizados nas tecnologias de antenas.

### 2.1 EQUAÇÕES DE MAXWELL

As equações de Maxwell fornecem uma descrição completa dos fenômenos eletromagnéticos, e servem de base para os sistemas modernos de comunicação e informação.

Apesar de levar o nome de Maxwell, as equações foram frutos de estudos de outros cientistas, no entanto foi Maxwell a observar a correlação entre elas e sintetizar os conceitos referentes aos campos elétricos, magnéticos e a luz. Dando assim um salto conceitual que originaria a teoria eletromagnética, permitindo grandes avanços tecnológicos no mundo e sendo até hoje fundamental nos estudos referentes às engenharias elétrica e eletrônica (MAXWELL; TORRANCE, 1996).

Na forma diferencial, as equações de Maxwell podem ser escritas da seguinte forma:

$$\nabla \times \mathcal{E} = -\mathcal{M} - \frac{\partial \mathcal{B}}{\partial t} \quad (2.1)$$

$$\nabla \times \mathcal{H} = \mathcal{J} + \frac{\partial \mathcal{D}}{\partial t} \quad (2.2)$$

$$\nabla \cdot \mathcal{D} = \rho \quad (2.3)$$

$$\nabla \cdot \mathcal{B} = 0 \quad (2.4)$$

A Lei de Faraday, Eq. (2.1), descreve a relação de um fluxo magnético num circuito fechado e a geração de uma força eletromotriz nesse mesmo circuito. Já Lei de Ampère-Maxwell, a Eq. (2.2), mostra que um campo magnético pode ser gerado a partir de um fluxo de correntes elétricas e por campo elétrico variante no tempo.

A Lei de Gauss, Eq. (2.3), descreve o campo de força elétrico em torno de uma distribuição de carga elétrica  $\rho$ . E por último, a Lei de Gauss para o magnetismo, Eq.(2.4), mostra que as linhas de campo do fluxo magnético fluem em caminho fechado, implicando na existência do dipolo magnético.

## 2.2 EQUAÇÃO DE ONDA

As equações de Maxwell são equações diferenciais parciais de primeira ordem, o que significa que há mais de um campo desconhecido. No entanto, são equações que podem ser combinadas e com o desenvolvimento algébrico, é possível conhecer o comportamento dos campos de maneira analítica. De mesma maneira, é possível descrever o comportamento da luz como sendo uma onda eletromagnética (MAXWELL; TORRANCE, 1996).

### 2.2.1 Equação de Onda de Helmholtz

A equação de onda de Helmholtz, de maneira escalar é escrita como:

$$\nabla^2 \Psi + k^2 \Psi = 0 \quad (2.5)$$

Onde  $\nabla^2$  é o operador laplaciano,  $\Psi$  a função de onda e  $k$  uma constante definida por número de onda.

Considerando que a onda possui formato esférico, a Eq.(2.5) pode ser reescrita em coordenadas esféricas, assumindo a seguinte forma:

$$\frac{1}{r^2} \frac{\partial}{\partial r} \left( r^2 \frac{\partial \Psi}{\partial r} \right) + \frac{1}{r^2 \sin \theta} \frac{\partial}{\partial \theta} \left( \sin \theta \frac{\partial \Psi}{\partial \theta} \right) + \frac{1}{r^2 \sin^2 \theta} \frac{\partial^2 \Psi}{\partial \phi^2} + k^2 \Psi = 0 \quad (2.6)$$

Sabendo que  $r, \theta$  e  $\phi$  são linearmente independentes, então a resolução pode ser dada por separação de variáveis. Sendo assim:

$$\Psi_{(r,\theta,\phi)} = R_{(r)} \Theta_{(\theta)} \Phi_{(\phi)} \quad r \geq 0, \theta \in [0, \pi], \phi \in [0, 2\pi[ \quad (2.7)$$

### 2.2.2 Solução para a Equação de Onda

A solução para a equação de onda vai depender das condições de contorno, ou seja, as condições iniciais do meio. Dado um meio linear, homogêneo e isotrópico, num espaço livre de fontes e desprezando pequenas não linearidades.

Após a substituição da Eq.2.7 na Eq.2.6, com algumas manipulações algébricas, obtem-se:

$$\frac{1}{r^2} \frac{1}{R_{(r)}} \frac{\partial}{\partial r} \left( r^2 \frac{\partial R_{(r)}}{\partial r} \right) + \frac{1}{r^2 \sin \theta} \frac{1}{\Theta_{(\theta)}} \frac{\partial}{\partial \theta} \left( \sin \theta \frac{\partial \Theta_{(\theta)}}{\partial \theta} \right) + \frac{1}{r^2 \sin^2 \theta} \frac{1}{\Phi_{(\phi)}} \frac{\partial^2 \Phi_{(\phi)}}{\partial \phi^2} + k^2 = 0 \quad (2.8)$$

Utilizando o método de separação das variáveis, atendendo-se para as constantes de separação e o comportamento físico individual de cada função, com algumas manipulações algébricas é possível chegar no seguinte conjunto solução:

$$\frac{d}{dr} \left( r^2 \frac{dR}{dr} \right) + [(kr)^2 - n(n+1)]R = 0 \quad (2.9)$$

$$\frac{1}{\sin \theta} \frac{d}{d\theta} \left( \sin \theta \frac{d\Theta}{d\theta} \right) + \left[ n(n+1) + \frac{m^2}{\sin^2 \theta} \right] \Theta = 0 \quad (2.10)$$

$$\frac{d^2 \Phi}{d\phi^2} + m^2 \Phi = 0 \quad (2.11)$$

A Eq. 2.9 assume a forma das funções esféricas de Bessel de ordem  $n$ . Sabendo que a potência total é finita, então a onda termina na origem. Quando observada longe da origem do sistema de coordenadas, tem estrutura esférica ao se propagar. No caso, somente a função de Bessel de primeira espécie satisfaz a primeira propriedade, enquanto a segunda só é satisfeita pela função esférica de Hankel, também conhecida como função esférica de Bessel de quarta ordem.

A síntese de todos esses resultados leva ao formato da função de onda escalar  $\Psi$ , solução da equação escalar de Helmholtz,

$$\Psi_{(r,\theta,\phi)} = \sum_{n=1}^{+\infty} \sum_{m=0}^n \sum_{s=1,4} \sum_{\sigma=e,o} a_{mn}^{\sigma s} \Psi_{mn}^{\sigma s}(r, \theta, \phi) \quad (2.12)$$

com

$$\Psi_{mn}^{\sigma s}(r, \theta, \phi) = Z_n^s(kr) P_n^m \cos(\theta) f_m^\sigma(\phi) \quad (2.13)$$

$$f_m^\sigma(\phi) = \sin(m\phi), \quad \text{se } \sigma = e \quad (2.14)$$

$$= \cos(m\phi), \quad \text{se } \sigma = o \quad (2.15)$$

$Z_n^1$ , função esférica de Bessel de primeira espécie e ordem  $n$ ,

$Z_n^4$ , função esférica de Hankel de segunda espécie e ordem  $n$ ,

$P_n^m$ , polinômio de Legendre de grau  $n$  e ordem  $m$ .

### 2.2.3 Solução para Equação de Onda Vetorial

Estendendo a solução da equação de onda para vetores, é conveniente adotar as seguintes condições:  $n \in \mathbb{N}$ ;  $m = 0, 1, \dots, n$ ;  $\sigma \in \{e, o\}$  e  $s \in \{1, 4\}$ .

$$\vec{M}_{mn}^{\sigma s} = \vec{\nabla} \times (\Psi_{mn}^{\sigma s} \vec{r}) \quad (2.16)$$

$$\vec{N}_{mn}^{\sigma s} = \frac{1}{k} \vec{\nabla} \times \vec{\nabla} \times (\Psi_{mn}^{\sigma s} \vec{r}) \quad (2.17)$$

$$\vec{L}_{mn}^{\sigma s} = \frac{1}{k} \vec{\nabla} \Psi_{mn}^{\sigma s}. \quad (2.18)$$

É fácil ver que  $\vec{N}_{mn}^{\sigma s} = \vec{\nabla} \times \vec{M}_{mn}^{\sigma s} / k$ , além de concluir que  $\vec{M}_{mn}^{\sigma s}$  e  $\vec{N}_{mn}^{\sigma s}$  são ortogonais. Dadas as considerações, com algumas manipulações básicas algébricas é possível concluir que os vetores  $\vec{L}_{mn}^{\sigma s}$ ,  $\vec{M}_{mn}^{\sigma s}$  e  $\vec{N}_{mn}^{\sigma s}$  são soluções para a equação de Helmholtz.

### 2.2.4 Solução para Equação de Onda do Campo Eletromagnético

A partir das considerações feitas até aqui, é possível chegar no formalismo para a solução geral das equações de campo elétrico e magnético, são respectivamente:

$$\vec{E} = \sum_{n=1}^{+\infty} \sum_{m=0}^n \sum_{s=1,4} \sum_{\sigma=e,o} a_{mn}^{\sigma s} \vec{M}_{mn}^{\sigma s} + b_{mn}^{\sigma s} \vec{N}_{mn}^{\sigma s} \quad (2.19)$$

$$\vec{H} = \frac{j}{\eta} \sum_{n=1}^{+\infty} \sum_{m=0}^n \sum_{s=1,4} \sum_{\sigma=e,o} a_{mn}^{\sigma s} \vec{M}_{mn}^{\sigma s} + b_{mn}^{\sigma s} \vec{N}_{mn}^{\sigma s} \quad (2.20)$$

Para a definição dos vetores  $M$  e  $N$ , ver anexos.



## 2.3 PARÂMETROS FUNDAMENTAIS

As antenas de radiofrequência (RF) possuem duas funções. A primeira é a de radiar a energia em radiofrequências geradas no transmissor e guiadas por uma linha de transmissão. E a outra função é de dirigir a energia numa determinada região, suprimindo a radiação onde não se necessita (JORDAN; BALMAIN, 1973).

O desempenho da antena é definido a partir dos parâmetros fundamentais, podendo estes serem correlacionados ou não. Esses parâmetros são definidos por diagramas de radiação, diretividade e região de campo (BALANIS, 2016).

### 2.3.1 Região de Campo

Conhecida como o espaço interno que envolve uma antena, a região de campo é dividida em três partes:

- Região de campo próximo reativo;
- Região de campo próximo radiante - Região de Fresnel;
- Região de campo distante - Região de Fraunhofer;




Figura 5 – Regiões de campo

A região de campo reativo se refere ao campo próximo imediatamente ao redor da antena.

A Região de Fresnel, também conhecido por *Near Field*(NF), onde predomina a distribuição angular dos campos dependentes da distância à antena e o campo radiante. A fronteira da região é dada pela seguinte relação:  $0.62\sqrt{D^3/\lambda} \leq R < 2D^2/\lambda$ , sendo  $R$  a

distância medida,  $D$  a máxima dimensão da antena e  $\lambda$  o comprimento de onda irradiado. Nessa região, o diagrama de radiação é dado em função da distância radial, ou seja, todas as componentes do campo  $(r, \theta, \phi)$  devem ser consideradas (BALANIS, 2016).

A Região de Fraunhofer, ou *Far Field* (FF), é a região de campo distante onde a distribuição angular dos campos já não depende da distância da antena e suas componentes de campo são essencialmente transversais  $(\theta, \phi)$  (BALANIS, 2016).

### 2.3.2 Diagrama de radiação

O diagrama de radiação é a representação gráfica das propriedades de radiação da antena em função das coordenadas espaciais. Nas propriedades de radiação, temos a densidade de fluxo de potência, intensidade de radiação, intensidade de campo, diretividade, fase e polarização. O diagrama pode ser de campo, representando a magnitude do campo elétrico ou magnético em função do espaço, ou de potência, representando graficamente o quadrado da magnitude do campo em função do espaço.

### 2.3.3 Vetor de Poynting

O Vetor de Poynting é a densidade direcional de potência associada às ondas eletromagnéticas.

$$\mathcal{S} = \mathcal{E} \times \mathcal{H} \quad (2.21)$$

A potência total do campo pode ser obtida a partir da integração na superfície fechada do vetor de Poynting, podendo ser definida como:

$$\mathcal{P} = \oint_s \mathcal{S} \cdot \hat{n} da \quad (2.22)$$

### 2.3.4 Diretividade

A diretividade só pode ser medida em radiadores não-isotrópicos, uma vez que, de acordo com a definição do *Institute of Electrical and Electronics Engineers* (IEEE) ela consiste na proporção da intensidade da radiação em uma determinada direção em relação a intensidade média em todas as direções (IEEE..., 2014).

$$D(\theta, \phi) = 4\pi \frac{P(\theta, \phi)}{P_{tot}} \quad (2.23)$$

Onde  $P(\theta, \phi)$  se refere a potência radiada por unidade de ângulo sólido, e  $P_{tot}$  é a potência total radiada. Essa definição não leva em consideração as perdas relacionadas à dissipação ou reflexão da antena (DICH, 1997; BALANIS, 2016).

A potência radiada está associada ao campo elétrico em região distante e é obtido a partir da seguinte relação:

$$P(\theta, \phi) = \frac{1}{2\eta} [|E_\theta(\theta, \phi)|^2 + |E_\phi(\theta, \phi)|^2] \quad (2.24)$$

### 2.3.5 Métodos Numéricos

Tomar algumas medidas importantes das antenas pode ser um problema de grande complexidade, devido às limitações técnicas dos instrumentos de medição e até mesmo da quantidade de variáveis levadas em consideração. Fazer o uso de métodos de aproximação se torna fundamental para estimativa desses resultados.

Os artifícios computacionais avançados tornam-se indispensáveis na determinação de medidas que não são obtidas experimentalmente, sejam estas por meios limitações técnicas ou econômicas.



## 3 PROBLEMA DE FASE

O problema de fase é um tema antigo e recorrente nas áreas da física e engenharia, comumente associado à perda de informação relacionada à fase nos processos de medições físicas (PAUWELS et al., 2017).

Nos procedimentos para obtenção das medidas físicas, por questões técnicas e econômicas, usualmente afere-se apenas os parâmetros relacionados à amplitude do sinal, ou seja, o módulo da função (FUCHS et al., 2019).

### 3.1 TRANSFORMADA DE FOURIER

A Transformada de Fourier tem como objetivo representar uma função periódica  $f(x)$  como uma soma de funções senoidais, como uma forma de simplificar análises de funções que possuem simetria entre os domínios do tempo  $f(x)$  e frequência  $F(\omega)$ .

$$F(\omega) = \mathcal{F}\{f(x)\} = \int_{-\infty}^{\infty} f(x)e^{-j\omega \cdot x} dx \quad (3.1)$$

### 3.2 RECUPERAÇÃO DE FASE

A recuperação de fase é o processo algoritmo para solução do Problema de Fase, consiste em métodos para a recuperação da fase de um sinal complexo a partir da sua transformada de Fourier.

A recuperação de fase é um problema conhecido, definido como um problema de recuperar uma função a partir das magnitudes da Transformada de Fourier. Mais conhecido pelo termo em inglês *Phase Retrieval* (PR), geralmente aparece em vários campos da física, processamento de sinais, eletromagnetismo, mecânica quântica e astronomia (GROHS; KOPPENSTEINER; RATHMAIR, 2019).

O problema de PR pode ser expresso na forma:

$$y = \mathbf{A}x \quad (3.2)$$

sendo  $\mathbf{A}$  uma matriz de Fourier contendo os dados conhecidos, onde  $\mathbf{A} \in \mathbb{C}^{m \times n}$ ,  $x$  o sinal a ser recuperado de comprimento  $n$  e  $m$  o número de medidas realizadas. Para o problema aplicado à recuperação de fase da antena,  $\mathbf{A}$  refere-se às medidas, a função de Green discretizada no espaço livre que relaciona  $x$  ao campo de radiação de magnitude  $y$ . Enquanto a fase não for conhecida, se faz necessário a realização de mais medições, com

valor desconhecido de  $n$  para que o campo seja satisfatoriamente recuperado(FUCHS et al., 2019).

### 3.3 ALGORITMOS PARA RECUPERAÇÃO DE FASE

Uma classe popular de algoritmos baseia-se no uso de projeções alternativas entre as diferentes restrições. Para aumentar a probabilidade de recuperação correta, esses métodos exigem que as informações anteriores sejam muito precisas, por exemplo, conhecimento exato / ou "quase" exato do conjunto de suporte(SHECHTMAN; BECK; ELDAR, 2014; BAUSCHKE; COMBETTES; LUKE, 2002).

O algoritmo de Gerchberg-Saxton(GS) foi considerado um método pioneiro para a resolução do problema de recuperação de fase a partir de dois planos diferentes (o real e o de Fourier), posteriormente estendido por Fienup(PAUWELS et al., 2017). Esse algoritmo consiste na iteração das transformadas diretas e inversas de Fourier entre dois planos de medição(SITU; SUO; DAI, 2015). Algumas adaptações surgiram a partir do algoritmo GS, no entanto esse método pode ser sensível às variações de fase iniciais e a convergência demorada (FUCHS et al., 2019).

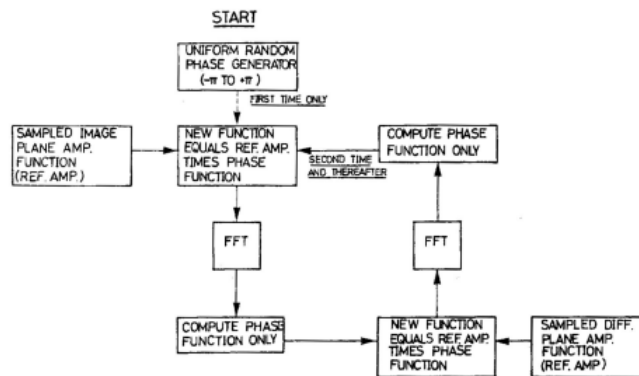


Figura 6 – Esquemático do algoritmo para determinar fase. Fonte: (GERCHBERG; SAXTON, 1972)

Uma abordagem mais recente para a recuperação de fases, baseado no método de Gauss-Newton, é o GESPAR (*Greedy Sparse Phase Retrieval*) capaz de formular a recuperação como um problema suave de estimativa de mínimos quadrados não-convexos e usar técnicas dedicadas para estimar o sinal usando algoritmos de otimização contínua que garantem a convergência para pontos estacionários(PAUWELS et al., 2017). O método não é restrito à magnitude de Fourier, no entanto quando as medidas são feitas no domínio de Fourier, o algoritmo se mostra eficiente a partir da rápida transformação de Fourier(SHECHTMAN; BECK; ELDAR, 2014).

Parte II

PROPOSTA





## 4 METODOLOGIA

O método utilizado para o trabalho fundamenta-se nas análises qualitativas e quantitativas. Uma vez que a quantidade de número de dados gerados diretamente proporcional às medidas, determinará a qualidade de dados a serem utilizados no desenvolvimento da inteligência artificial, que implicará na acurácia da reconstrução do modelo esperado.

### 4.1 JUSTIFICATIVA

O problema de recuperação da fase é antigo e recorrente, aparecido quando se faz medições baseadas apenas na obtenção de valores associados à magnitude do sinal. Por questões financeiras e técnicas, a recuperação da fase é um processo complexo.

No artigo publicado ([FUCHS et al., 2019](#)), demonstrou-se a possibilidade de recuperação de fase em campo próximo a partir de medidas de duas superfícies. Como o resultado se mostrou satisfatório, gerando uma grande quantidade de dados, abrindo margem para a exploração analítica dos dados e a partir disso buscar a reconstrução do campo distante sem que haja alguma alteração de *hardware* nos equipamentos de medição e custos adicionais.

### 4.2 OBJETIVOS

Esse trabalho faz parte da proposta elaborada para a conclusão do curso de Engenharia Eletrônica, buscando integrar todo o formalismo técnico e teórico adquirido durante a graduação, para então desenvolver um algoritmo de inteligência artificial objetivando a recuperação das informações de fase de uma antena, a partir de dados obtidos através de medidas de campo próximo.

#### 4.2.1 Objetivo específico

No que se refere à primeira etapa do trabalho de conclusão de curso, tem-se como objetivo:

- Revisão bibliográfica referente à IA, aprendizado de máquina e métodos mais utilizados, bem como a diferenciação entre os tipos e aplicabilidade;
- Formalismo teórico sobre antenas e principais parâmetros de análise;
- Revisão bibliográfica sobre problema de recuperação de fase;

### 4.3 Procedimento

O procedimento para desenvolvimento deste trabalho em primeiro momento consiste no estudo teórico referente aos modelos de inteligência artificial, áreas de aplicabilidade, algoritmos desenvolvidos, técnicas e áreas correlatadas, além das linguagens de programação mais utilizadas e o *tradeoff* entre os *software* de desenvolvimento. Em paralelo, o estudo teórico de caracterização de antenas e os aparatos matemáticos utilizados para descrição do comportamento em campo próximo e distante.

O referencial teórico se faz necessário para entender a natureza dos dados gerados e a sua interpretação física das medidas tomadas. Uma vez que as etapas experimentais já foram realizadas e o comportamento em campo próximo pode ser obtido a partir da solução da equação de onda 2.19 do campo elétrico.

Por meio de análise dos valores obtidos, utilizando técnicas de ML, correlacionando os dados de campo elétrico e fluxo de corrente, desenvolver o algoritmo que seja capaz de reconstruir a região de campo distante da antena. A simulação de campo distante para efeitos comparativos, será realizada utilizando o software específico HFSS 15.0. Já os algoritmos para o aprendizado de máquina, no MATLAB, dada a ampla biblioteca de apoio e facilidade no tratamento de dados pertencente ao domínio dos números complexos.

A recuperação de fase ocorrerá a partir de medidas conhecidas das fontes de corrente  $J$  e campo elétrico  $E$ , obtendo as componentes de potencial, conforme a relação demonstrada (BALANIS, 2016).




Figura 7 – Relação entre fluxo de corrente, campo e potencial

Essa relação é confirmada devido a natureza física das medidas, uma vez que são sinais de potência finita e podem ser representados por somas de sinais períodos, atendendo ao formalismo da transformada de Fourier. Ponto focal para que seja possível a obtenção das informações de amplitude e fase.

## 4.4 Métodos de Análise

## 4.5 Simulação

O modelo de antena em formato de corneta piramidal é comumente utilizado como fonte eletromagnética. Como a proposta do trabalho consiste na análise do campo elétrico, e não o estudo do modelo em si, adotou-se esse modelo para simulação. Adotando a geometria, conforme ilustrado na Fig.4.5.




Figura 8 – Antena do tipo Corneta Piramidal



## 5 CONCLUSÃO

### 5.1 CONCLUSÃO PARCIAL

As buscas literárias visaram o estudo da recuperação de fase e as metodologias ortodoxas utilizadas, bem como o sucesso nos resultados obtidos. Servindo então de apoio para a modelagem da proposta na elaboração do esquemático do algoritmo a ser desenvolvido.

Os trabalhos desenvolvidos na solução do problema de fase mostraram abordagem ampla na utilização de métodos numéricos já existentes. No entanto, houve dificuldade em encontrar fontes que fizessem o uso de algoritmos de aprendizado de máquina aplicados na solução do problema para antenas.

Foi possível constatar que o desenvolvimento de algoritmos robustos e associados ao *deep learning* é um ramo ainda em fase inicial, com aplicações satisfatórias e difundidas no processamento de sinais. No qual o formalismo matemático, com algumas considerações, pode ser aproximado ao eletromagnetismo.

Visando a eficiência do algoritmo, conclui-se a necessidade de testar diferentes métodos já desenvolvidos, para análise e estudo do que melhor se adequa aos dados de entrada, fornecendo a saída esperada com menor tempo de processamento e maior qualidade na reconstrução da fase.

### 5.2 CRONOGRAMA

Para o desenvolvimento da Inteligência Artificial como proposta de Trabalho de Conclusão de Curso 2, a metodologia adotada será Scrum, onde as etapas do projeto serão divididas em *sprints*, com entregas periódicas e previsão de conclusão alinhada ao calendário universitário 2/2020.

### 5.3 Tabela

Processing type	Property 1 (%)	Property 2 [ $\mu m$ ]
Process 1	40.0	22.7
Process 2	48.4	13.9
Process 3	39.0	22.5
Process 4	45.3	28.5

Tabela 1 – Propriedades obtidas após processamento

# Referências

- BALANIS, C. *Antenna Theory: Analysis and Design*. 4. ed. [S.l.]: WILEY, 2016. 23 p. ISBN 978-1-118-642060-1. Citado 4 vezes nas páginas 35, 39, 40 e 48.
- BAUSCHKE, H. H.; COMBETTES, P. L.; LUKE, D. L. Phase retrieval, error reduction algorithm, and fienup variants: a view from convex optimization. *J. Opt. Soc. Amer. A*, v. 19, p. 1334–1345, 2002. Citado na página 44.
- BELROSE, J. S. Fessenden and marconi: their differing technologies and transatlantic experiments during the first decade of this century. In: *Proceedings of the 1995 International Conference on 100 Years of Radio*. [S.l.: s.n.], 1995. p. 32–43. Citado na página 35.
- DELLINGER, J. H. Principles of radio transmission and reception with antenna and coil aerials. *Transactions of the American Institute of Electrical Engineers*, v. 38, n. 2, p. 1347–1414, Jul 1919. Citado na página 35.
- DHUMALE, R. B.; THOMBARE, N. D.; BANGARE, P. M. Machine learning: A way of dealing with artificial intelligence. In: *2019 1st International Conference on Innovations in Information and Communication Technology (ICIICT)*. [S.l.: s.n.], 2019. p. 1–6. Citado 5 vezes nas páginas 30, 31, 32, 33 e 34.
- DICH, M. Accurate determination of antenna directivity. *IEEE Transactions on Antennas and Propagation*, v. 45, n. 10, p. 1502–1505, Oct 1997. ISSN 1558-2221. Citado na página 40.
- FUCHS, B. et al. Phaseless near field antenna measurements from two surface scans - numerical and experimental investigations. *IEEE Transactions on Antennas and Propagation*, p. 1–1, Oct 2019. ISSN 1558-2221. Citado 3 vezes nas páginas 43, 44 e 47.
- GERCHBERG, R. W.; SAXTON, W. O. Practical algorithm for determination of phase from image and diffraction plane pictures. *Optik*, v. 35, n. 2, p. 237–&, 1972. ISSN 0030-4026. Citado 2 vezes nas páginas 15 e 44.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016. Disponível em: <<http://www.deeplearningbook.org>>. Citado na página 33.
- GROHS, P.; KOPPENSTEINER, S.; RATHMAIR, M. *The Mathematics of Phase Retrieval*. 2019. Citado na página 43.
- IEEE Standard Definitions of Terms for Antennas. *IEEE No 145-1973*, p. 1–18, Aug 1973. Citado na página 35.
- IEEE Standard for Definitions of Terms for Antennas. *IEEE Std 145-2013*, p. 1–50, Mar 2014. Citado na página 40.
- JORDAN, E. C.; BALMAIN, K. G. *Ondas Eletromagneticas y Sistemas Radiantes*. [S.l.: s.n.], 1973. ISBN 8428303819. Citado na página 39.

- KELLER, J. M.; GRAY, M. R.; GIVENS, J. A. A fuzzy k-nearest neighbor algorithm. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-15, n. 4, p. 580–585, Jul 1985. ISSN 2168-2909. Citado na página 33.
- KRAUS, J. D. Heinrich hertz-theorist and experimenter. *IEEE Transactions on Microwave Theory and Techniques*, v. 36, n. 5, p. 824–829, May 1988. Citado na página 35.
- LORENA, A.; CARVALHO, A. Uma introdução às support vector machines. *Revista de Informática Teórica e Aplicada; Vol. 14, No 2 (2007); 43-67*, v. 14, Dec 2007. Citado na página 33.
- MAJHI, B.; S.SABYASACHI; MISHRA, S. Classification of power signals using aco based k- means algorithm and fuzzy c-means algorithm. In: . [S.l.: s.n.], 2014. Citado na página 34.
- MAXWELL, J. C.; TORRANCE, T. F. *A Dynamical Theory of the Electromagnetic Field*. 0. ed. [S.l.: s.n.], 1996. ISBN 1579100155,9781579100155. Citado na página 36.
- MCCARTHY, J. et al. A proposal for the dartmouth summer research project on artificial intelligence. *AI Magazine*, n. 4, p. 12, Dec 2006. Citado na página 29.
- MIJWEL, M. History of artificial intelligence. v. 3, p. 1–8, Apr 2015. Citado na página 29.
- PAUWELS, E. et al. On fienup methods for regularized phase retrieval. *CoRR*, abs/1702.08339, Aug 2017. Disponível em: <<http://arxiv.org/abs/1702.08339>>. Citado 2 vezes nas páginas 43 e 44.
- RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 3rd. ed. [S.l.]: Prentice Hall, 2010. (Prentice Hall Series in Artificial Intelligence). ISBN 0136042597, 9780136042594. Citado 2 vezes nas páginas 30 e 32.
- SHABBIR, J.; ANWER, T. Artificial intelligence and its role in near future. *CoRR*, abs/1804.01396, Aug 2018. Citado na página 29.
- SHECHTMAN, Y.; BECK, A.; ELDAR, Y. C. Gspar: Efficient phase retrieval of sparse signals. *IEEE Transactions on Signal Processing*, v. 62, n. 4, p. 928–938, Feb 2014. ISSN 1941-0476. Citado na página 44.
- SIMEONE, O. A very brief introduction to machine learning with applications to communication systems. *CoRR*, abs/1808.02342, Sep 2018. Disponível em: <<http://arxiv.org/abs/1808.02342>>. Citado na página 30.
- SITU, G.; SUO, J.; DAI, Q. Generalized iterative phase retrieval algorithms and their applications. In: *2015 IEEE 13th International Conference on Industrial Informatics (INDIN)*. [S.l.: s.n.], 2015. p. 713–720. ISSN 2378-363X. Citado na página 44.
- TAULLI, T. *Artificial Intelligence Basics. A Non-Technical Introduction*. [S.l.]: Apress, 2019. ISBN 978-1-4842-5027-3. Citado 4 vezes nas páginas 30, 32, 33 e 34.



# Anexos



# ANEXO A – Vetores da Equação de Onda do Campo Eletromagnético

Por definição, os vetores  $\vec{M}_{mn}^{\sigma s}$  e  $\vec{N}_{mn}^{\sigma s}$ , são respectivamente:

$$\vec{M}_{mn}^{\sigma s}(r, \theta, \phi) = -t_{mn}^{\sigma 1}(\theta) \cdot Z_n^s(x) \cdot f_m^\sigma(\phi) \cdot \hat{\theta} + t_{mn}^{\sigma 2}(\theta) \cdot Z_n^s(x) \cdot f_m^{\bar{\sigma}}(\phi) \cdot \hat{\phi} \quad (\text{A.1})$$

$$\vec{N}_{mn}^{\sigma s}(r, \theta, \phi) = t_{mn}^{\sigma 3}(\theta) \cdot Z_n^s(x)/x \cdot f_m^{\bar{\sigma}}(\phi) \cdot \hat{r} - t_{mn}^{\sigma 2}(\theta) \cdot K_n^s(x) \cdot f_m^{\bar{\sigma}}(\phi) \cdot \hat{\theta} - t_{mn}^{\sigma 1}(\theta) \cdot K_n^s(x) \cdot f_m^\sigma(\phi) \cdot \hat{\phi} \quad (\text{A.2})$$

$$x = kr \quad (\text{A.3})$$

$$f_m^\sigma(\phi) = \sin(m\phi), \quad \text{se } \sigma = e, \quad (\text{A.4})$$

$$= \cos(m\phi), \quad \text{se } \sigma = o \quad (\text{A.5})$$

$$\sigma(-1) = +1, \text{ se } \sigma = o \quad (\text{A.6})$$

$$= -1, \text{ se } \sigma = e \quad (\text{A.7})$$

$$t_{mn}^{\sigma 1} = \bar{\sigma}(-1) m \frac{P_n^m(\cos\theta)}{\sin\theta} \quad (\text{A.8})$$

$$t_{mn}^{\sigma 2} = -\frac{\partial}{\partial\theta} P_n^m(\cos\theta) \quad (\text{A.9})$$

$$t_{mn}^{\sigma 3} = n(n+1) \cdot P_n^m(\cos\theta) \quad (\text{A.10})$$